Chapitre 6 : Statistiques descriptives

Frederik de Peyrelongue

I Définitions et vocabulaire

— L'ensemble sur lequel porte l'étude statistique s'appelle la **population**. Un élément de la population s'appelle un **individu**. L'objet étudié s'appelle le **caractère**.

— Si le caractère étudié prend des **valeurs numériques**, on dit qu'il est **quantitatif**. Sinon, on dit qu'il est **qualitatif**.

— Un caractère quantitatif peut être **discret** (il prend des valeurs isolées) ou **continu** (il prend toute valeur dans un intervalle appelé classe).

— Les différentes valeurs prises par un caractère s'appellent les **modalités** (ou modes).

— L'**effectif** d'une valeur est le nombre d'individus ayant cette valeur.

— L'**effectif total** (noté N) est le nombre d'individus dans la population étudiée.

— La **fréquence** d'une valeur est :

$$f = \frac{\text{Effectif d'une valeur}}{\text{Effectif total}}.$$

On peut résumer les données d'une série statistique par un tableau.

Caractéristique étudiée	Valeur 1	Valeur 2	...	Valeur n
Effectif				
Fréquence				

II Médiane et écart interquartile

2.1 La médiane, indicateur de tendance centrale de la série

Définition — Médiane

Soit une série de N valeurs rangées par ordre croissant. La **médiane** Me est le nombre défini par :

— si N est impair, Me est la valeur centrale : elle correspond au rang $\frac{N+1}{2}$ dans la série classée par ordre croissant ;

— si N est pair, Me est la moyenne des deux valeurs centrales, c'est-à-dire la moyenne des valeurs ayant les positions $\frac{N}{2}$ et $\frac{N}{2}+1$.

Méthode :

1) Ordonner la série par ordre croissant.

2) Compléter les effectifs.

3) Compléter les effectifs cumulés croissants (E.C.C.).

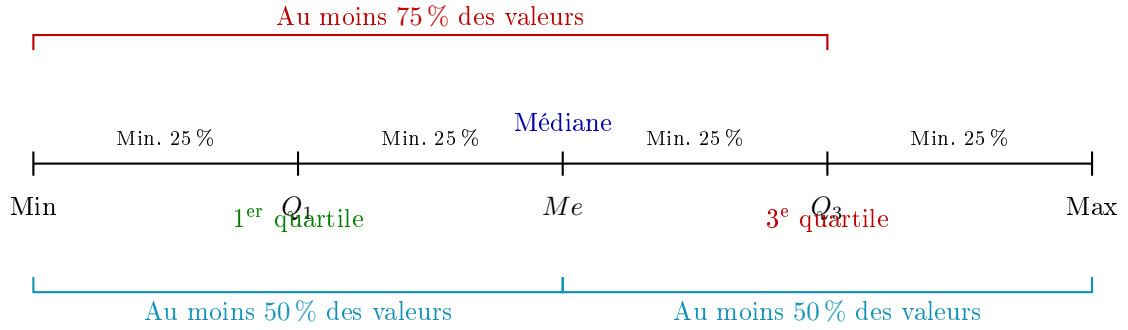
4) Selon que N est pair ou non, venir chercher la valeur centrale ou les deux valeurs centrales.

2.2 Les quartiles

Définition — Quartiles

— Le **premier quartile**, noté Q_1, est la plus petite valeur de la série telle qu'au moins 25 % des valeurs soient inférieures ou égales à Q_1.

— Le **troisième quartile**, noté Q_3, est la plus petite valeur de la série telle qu'au moins 75 % des valeurs soient inférieures ou égales à Q_3.



Le **rang** du 1er quartile d'une série de N valeurs est le plus petit entier supérieur ou égal à $\frac{N}{4}$.

Le **rang** du 3e quartile est le plus petit entier supérieur ou égal à $\frac{3N}{4}$.

2.3 L'écart interquartile : un indicateur de dispersion

Définition — Écart interquartile

— L'**écart interquartile** est la différence $Q_3 - Q_1$.

— L'**intervalle interquartile** est l'intervalle $[Q_1\,;Q_3]$.

L'écart interquartile indique la longueur de l'intervalle dans lequel la moitié centrale des valeurs de la série sont comprises.

Propriété — Moitié centrale

Au moins 50 % des valeurs de la série sont comprises dans l'intervalle interquartile.

III Moyenne et écart-type

On considère ici la série statistique donnée dans le tableau ci-dessous, et on note $N = n_1+n_2+\cdots+n_p$ l'effectif total.

Valeur	x_1	x_2	$\ldots$	x_p
Effectif	n_1	n_2	$\ldots$	n_p

3.1 La moyenne pondérée : indicateur de tendance centrale

Définition — Moyenne pondérée

La **moyenne pondérée** de la série ci-dessus est le nombre, noté $\overline{x}$, tel que :

$$\overline{x} = \frac{n_1x_1 + n_2x_2 + \cdots + n_px_p}{N}.$$

Exemple — Nombre d'appels reçus par jour

Nombre d'appels reçus par jour par un standardiste pendant 20 jours :

Nombre d'appels	8	9	11	12	14	16
Effectif	1	3	5	5	2	4

$$\overline{x} = \frac{n_1x_1 + n_2x_2 + \cdots + n_px_p}{N} = \frac{8\times 1 + 9\times 3 + 11\times 5 + 12\times 5 + 14\times 2 + 16\times 4}{20} \approx 12{,}1.$$

En moyenne, ce standardiste reçoit 12,1 appels par jour.

Propriété — Linéarité de la moyenne

Soient a et b deux nombres réels.
Si une série de valeurs $(x_i)_{1\leqslant i\leqslant p}$ a pour moyenne $\overline{x}$, alors la série de valeurs $(a\,x_i + b)_{1\leqslant i\leqslant p}$ a pour moyenne $a\,\overline{x} + b$.

Preuve : calculons la moyenne de la série $(a\,x_i + b)$:

$$\frac{n_1(ax_1+b) + n_2(ax_2+b) + \cdots + n_p(ax_p+b)}{N} = \frac{a\,(n_1x_1 + \cdots + n_px_p) + b\,(n_1 + \cdots + n_p)}{N}$$

$$= a \times \frac{n_1x_1 + \cdots + n_px_p}{N} + b \times \frac{n_1 + \cdots + n_p}{N} = a\,\overline{x} + b \times \frac{N}{N} = a\,\overline{x} + b.$$

3.2 L'écart-type : un indicateur de dispersion

Définition — Écart-type

L'**écart-type** d'une série de valeurs $(x_i)_{1\leqslant i\leqslant p}$ est le nombre positif, noté σ, défini par :

$$\sigma = \sqrt{\frac{n_1\,(x_1-\overline{x})^2 + n_2\,(x_2-\overline{x})^2 + \cdots + n_p\,(x_p-\overline{x})^2}{N}}.$$

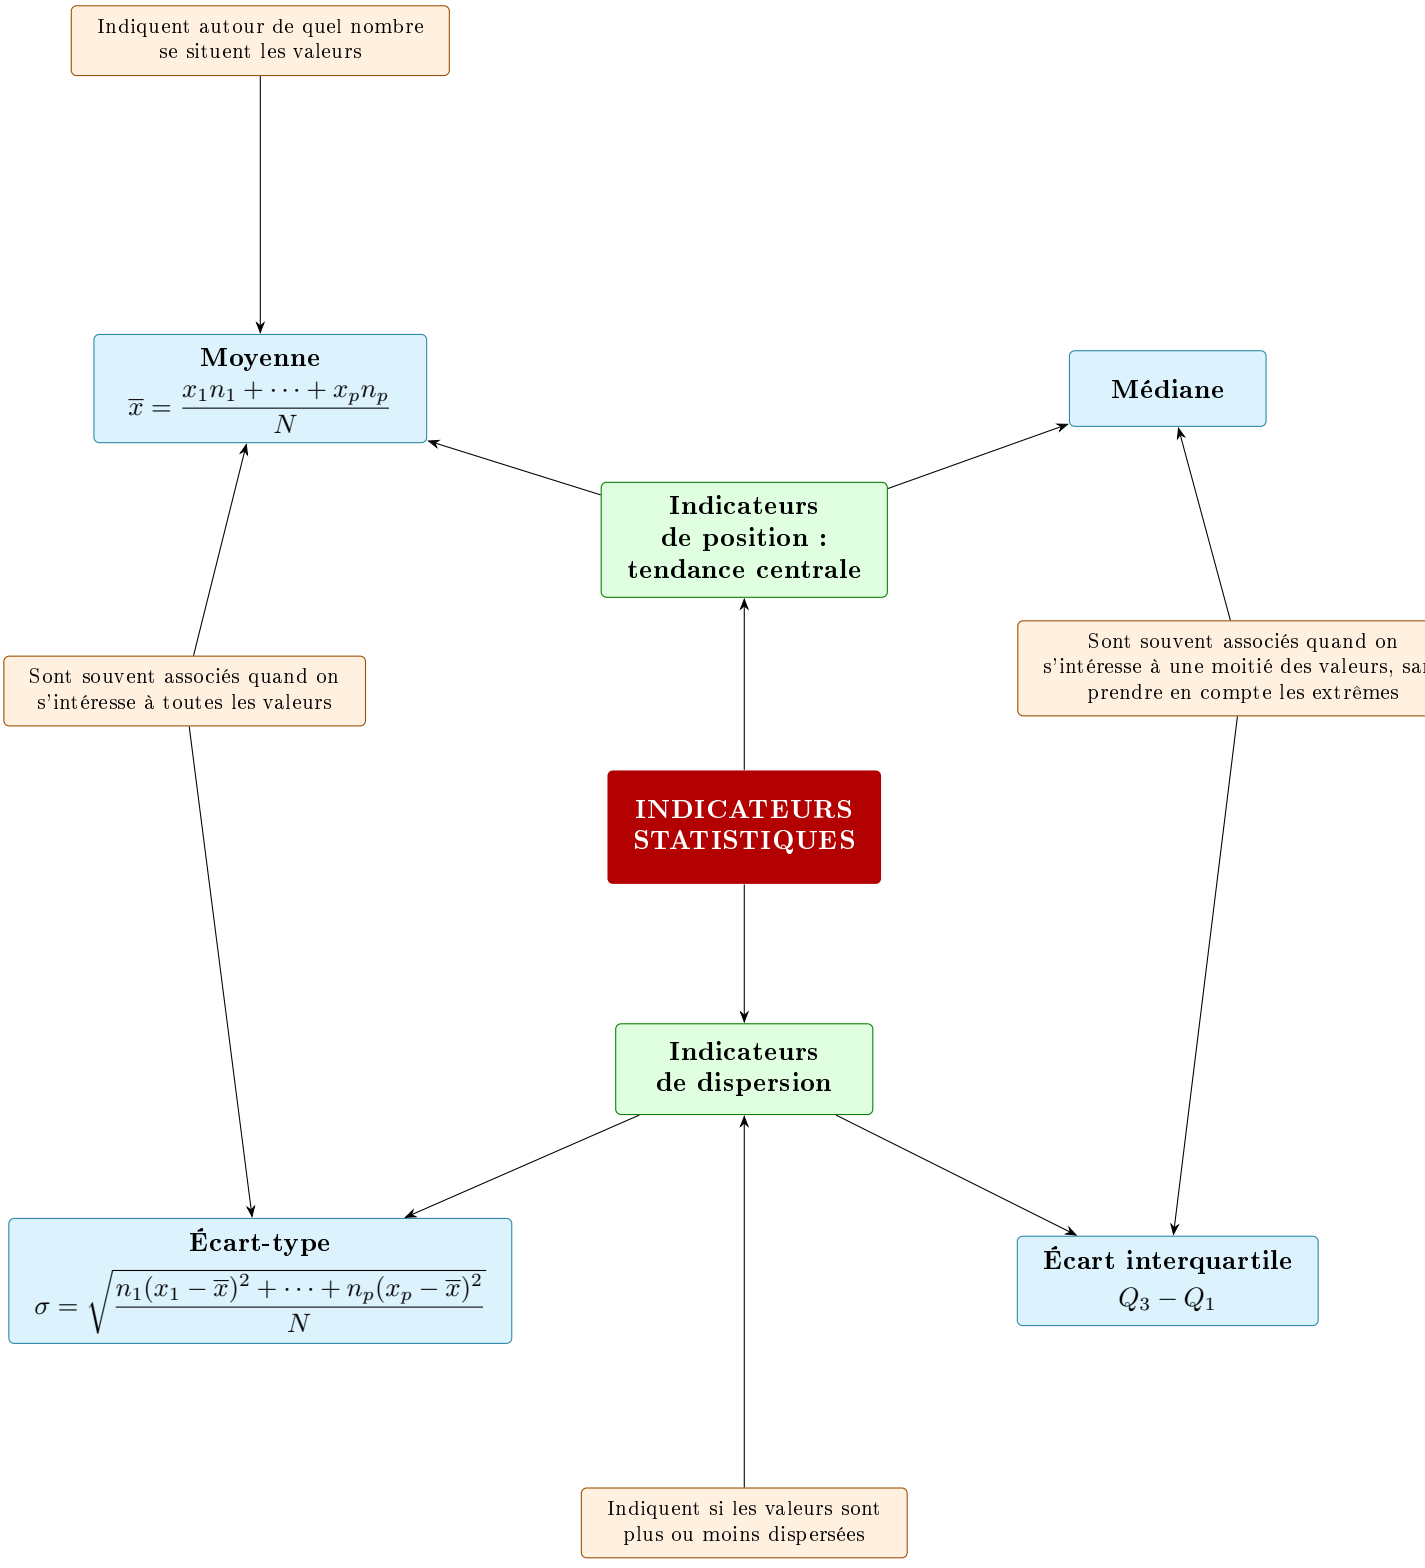
Plus l'écart-type est grand, plus les valeurs sont dispersées autour de la moyenne.

Exemple — Écart-type de la série précédente

On reprend l'exemple précédent :

$$\sigma = \sqrt{\frac{(8-12{,}1)^2\times 1 + (9-12{,}1)^2\times 3 + (11-12{,}1)^2\times 5 + (12-12{,}1)^2\times 5 + (14-12{,}1)^2\times 2 + (16-12{,}1)^2}{20}}$$

En moyenne, le nombre d'appels par jour s'écarte de 2,4 par rapport à $\overline{x}$.


Indiquent autour de quel nombre se situent les valeurs
Moyenne
$\overline{x} = \frac{x_1 n_1 + \cdots + x_p n_p}{N}$
Médiane
Indicateurs de position : tendance centrale
Sont souvent associés quand on s'intéresse à toutes les valeurs
Sont souvent associés quand on s'intéresse à une moitié des valeurs, sa
prendre en compte les extrêmes
INDICATEURS STATISTIQUES
Indicateurs de dispersion
Écart-type
$\sigma = \sqrt{\frac{n_1(x_1 - \overline{x})^2 + \cdots + n_p(x_p - \overline{x})^2}{N}}$
Écart interquartile
$Q_3 - Q_1$
Indiquent si les valeurs sont plus ou moins dispersées