Chapitre VI : Statistique à deux variables

Frederik de Peyrelongue

I Tableau d'effectifs – Nuage de points

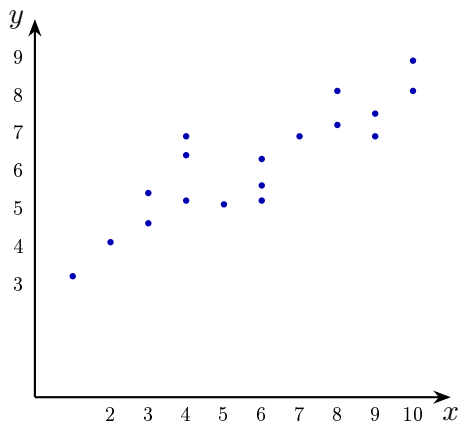
On considère deux caractères simultanément : x et y, dont on donne les données dans un tableau d'effectifs.

x_i	x_1	x_2	$\dots$	x_p
y_i	y_1	y_2	$\dots$	y_p

Ces données peuvent être représentées par un nuage de points de coordonnées $(x_i\,;y_i)$.

Définition — Nuage de points

L'ensemble des points M_i de coordonnées $(x_i\,;y_i)$ est appelé **nuage de points** associé à la série statistique $(x_1\,;y_1), (x_2\,;y_2), \dots, (x_n\,;y_n)$ à deux variables.



Définition — Point moyen

Le point G de coordonnées $(\overline{x}\,;\overline{y})$, où $\overline{x}$ et $\overline{y}$ sont les moyennes respectives des x_i et des y_i, est appelé le **point moyen** du nuage de points associé à la série.

Exercice

Le tableau suivant présente l'évolution du budget publicitaire et du chiffre d'affaires d'une société au cours des 6 dernières années :

Budget publicitaire en milliers d'euros x_i	8	10	12	14	16	18
Chiffre d'affaire en milliers d'euros y_i	40	55	55	70	75	95

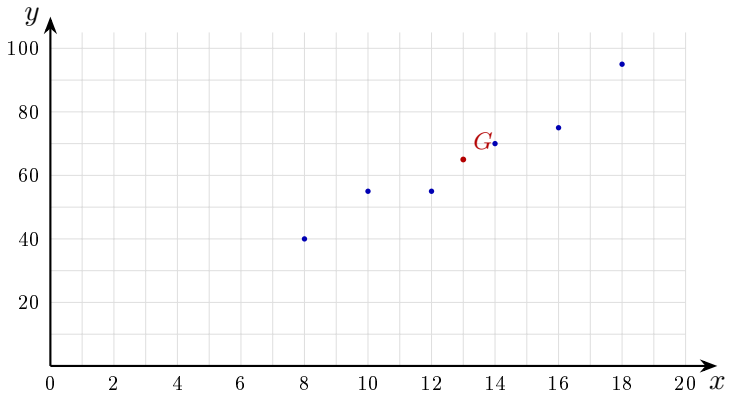
1) Dans un repère, représenter le nuage de points $(x_i\,;y_i)$.

2) Déterminer les coordonnées du point moyen G du nuage de points.

Correction. On a représenté ci-dessous le nuage de points de la série $(x_i\,;y_i)$.

$$\overline{x} = \frac{8+10+12+14+16+18}{6} = 13 \qquad \overline{y} = \frac{40+55+55+70+75+95}{6} = 65.$$

Le point moyen G du nuage de points a pour coordonnées $(13\,;65)$. On peut placer ce point dans le repère.



II Ajustement affine

Dans certaines situations, le nuage de points semble donner un ensemble de points presque alignés. On va alors dans ces cas faire un ajustement affine, c'est-à-dire trouver une droite d'équation $y = ax + b$ qui permet de représenter cette série.

II.1 Interpolation, extrapolation

L'objectif est, à partir des valeurs d'une série statistique à deux variables, d'obtenir des approximations pour des valeurs inconnues de cette série.

Exemple — Budget pour un chiffre d'affaires de 80 Mio

Quelle serait le budget publicitaire pour un chiffre d'affaires de 80 Mio ?
Ici, on est dans le domaine d'étude de la série : le chiffre d'affaires a été étudié entre 40 Mio et 95 Mio. L'estimation que l'on donnera sera une **interpolation**.

Exemple — Budget pour un chiffre d'affaires de 100 Mio

Quelle serait le budget publicitaire pour un chiffre d'affaires de 100 Mio ?
Ici, on est en dehors du domaine d'étude de la série. L'estimation que l'on donnera sera une **extrapolation**.

Définition — Interpolation et extrapolation

L'**interpolation** et l'**extrapolation** sont des méthodes qui consistent à estimer une valeur inconnue dans une série statistique.

— Pour une interpolation, le calcul est réalisé dans le domaine d'étude fourni par les valeurs de la série.

— Pour une extrapolation, le calcul est réalisé en dehors du domaine d'étude.

Remarque. La méthode d'extrapolation est parfois contestable, car en dehors du domaine d'étude fourni par les valeurs de la série, rien ne nous assure que le modèle mathématique mis en œuvre soit encore valable.

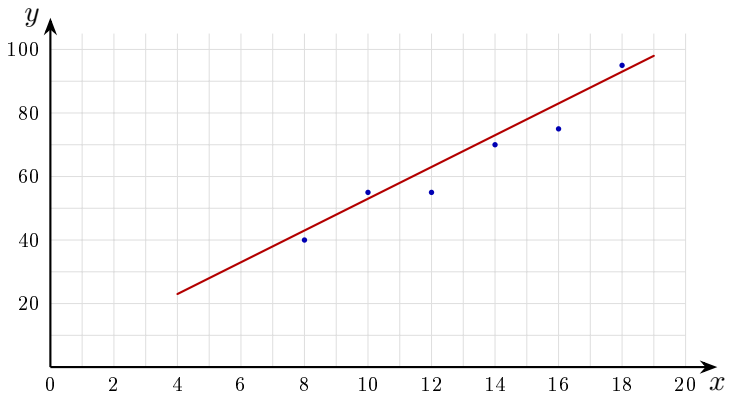
II.2 Droite d'ajustement

Pour obtenir de telles estimations, il faudra déterminer une droite passant « le plus près possible » des points du nuage.

L'interpolation ou l'extrapolation consiste à effectuer l'estimation par lecture graphique sur la droite ou par calcul à l'aide de l'équation de la droite.

Définition — Droite d'ajustement

Lorsque les points d'un nuage sont sensiblement alignés, on peut construire une droite, appelée **droite d'ajustement** (ou **droite de régression**), passant « au plus près » de ces points.



II.3 Méthode à main levée

Sans technique particulière, on trace « au jugé » une droite passant « au plus près » des points du nuage, puis on détermine l'équation de cette droite $y = ax + b$.

On peut alors utiliser cette droite pour faire des estimations de valeur théorique de y pour $x = 9$, par exemple.

II.4 Méthode des points moyens (ajustement de Mayer)

Cet ajustement consiste à déterminer la droite passant par deux points moyens du nuage de points.

Exercice

Déterminer la droite d'ajustement par la méthode des points moyens. On reprend les données du paragraphe I.

1) Soit G_1 le point moyen associé aux trois premiers points du nuage et G_2 le point moyen associé aux trois derniers points du nuage.

- **a)** Calculer les coordonnées de G_1 et G_2.
- **b)** On prend (G_1G_2) comme droite d'ajustement. Tracer cette droite.

2) À l'aide du graphique :

- **a)** Estimer le chiffre d'affaire à prévoir pour un budget publicitaire de 22 000 €.
- **b)** Estimer le budget publicitaire qu'il faudrait prévoir pour obtenir un chiffre d'affaire de 100 000 €.
- **c)** La méthode utilisée dans les questions 2a et 2b consiste-t-elle en une interpolation ou une extrapolation ?

Correction.

1) a)

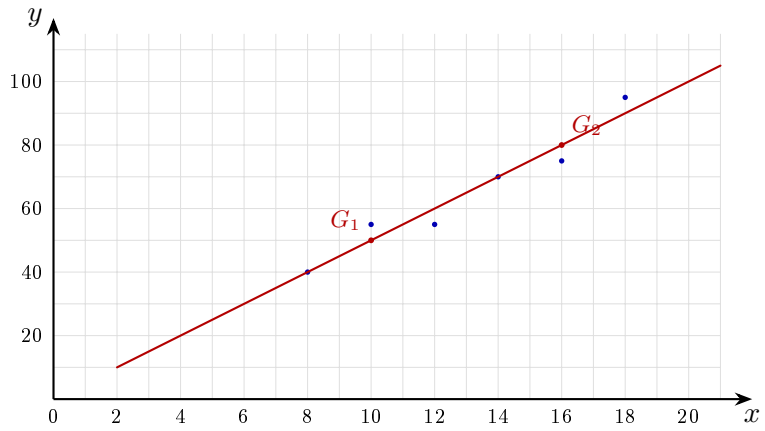
$$\overline{x_1} = \frac{8+10+12}{3} = 10 \qquad \overline{y_1} = \frac{40+55+55}{3} = 50.$$

Le point moyen G_1 a pour coordonnées $(10\,;50)$.

$$\overline{x_2} = \frac{14+16+18}{3} = 16 \qquad \overline{y_2} = \frac{70+75+95}{3} = 80.$$

Le point moyen G_2 a pour coordonnées $(16\,;80)$.

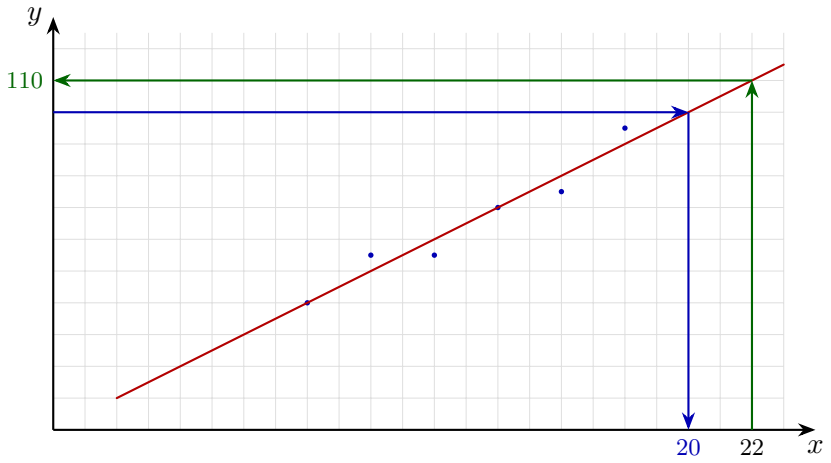
b) La droite (G_1G_2) a pour coefficient directeur $\dfrac{80-50}{16-10} = 5$, donc pour équation $y = 5x$.



2) On lit graphiquement :

a) Le chiffre d'affaires à prévoir pour un budget publicitaire de 22 000 € est de 110 000 €.

b) Le budget publicitaire qu'il faudrait prévoir pour obtenir un chiffre d'affaire de 100 000 € est de 20 000 €.



c) Les lectures graphiques sont réalisées ici en dehors du domaine d'étude : on parle donc d'**extrapolation**.

II.5 Méthode des moindres carrés

Cette méthode porte le nom de « moindres carrés » car elle consiste à rechercher la position de la droite d'ajustement telle que la somme des carrés des longueurs donnant les distances respectives entre la droite et les points soit minimale.

Le principe consiste donc à déterminer les coefficients a et b d'une droite d'équation $y = ax + b$ de sorte qu'elle passe le « plus près possible » des points du nuage.

Pour chaque abscisse x_i, on calcule la distance M_iP_i entre le point du nuage et le point de la droite, soit :

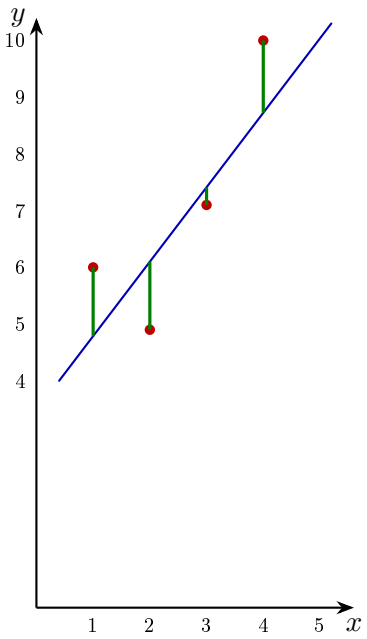
$$M_iP_i = |y_i - (ax_i + b)|\,.$$

Il s'agit dans ce cas de la droite d'ajustement de y en x.

Dans la méthode des moindres carrés, on recherche a et b pour lesquels la somme des carrés des distances est minimale, soit :

$$M_1P_1^2 + \cdots + M_nP_n^2 = \big(y_1 - (ax_1 + b)\big)^2 + \cdots + \big(y_n - (ax_n + b)\big)^2$$

est minimale.



Exercice

Déterminer la droite d'ajustement par la méthode des moindres carrés.
On considère la série statistique à deux variables données dans le tableau suivant :

x_i	5	10	15	20	25	30	35	40
y_i	13	23	34	44	50	65	75	90

1) Dans un repère, représenter le nuage de points $(x_i\,;y_i)$.

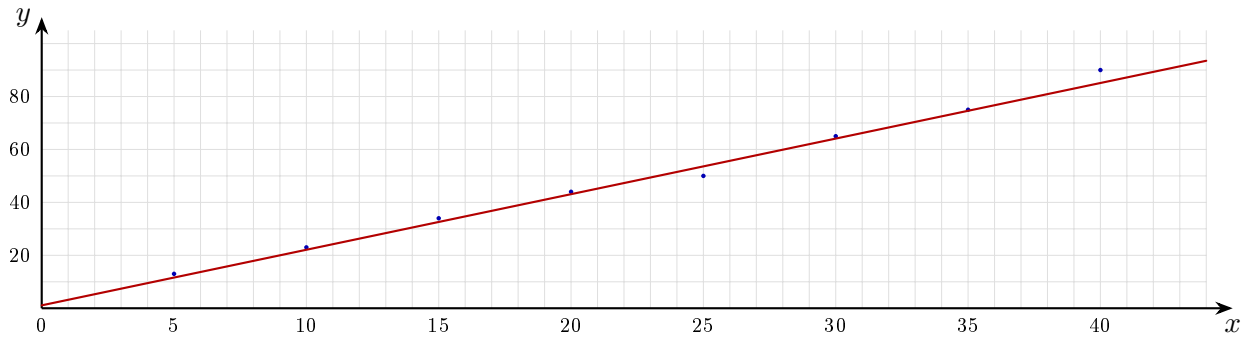
2) a) À l'aide de la calculatrice, déterminer une équation de la droite d'ajustement par la méthode des moindres carrés.

b) Représenter la droite d'ajustement de y en x.

3) Estimer graphiquement la valeur de x pour $y = 70$. Retrouver ce résultat par calcul. S'agit-il d'une interpolation ou d'une extrapolation ?

Correction.

1) et **2) b)**



2) a)

Avec TI :
- Appuyer sur « STATS » puis « Édite » et saisir les valeurs de x dans L1 et les valeurs de y dans L2.
- Appuyer à nouveau sur « STATS » puis « CALC » et « RegLin(ax+b) ».
- Saisir L1,L2.

Avec CASIO :
- Aller dans le menu « STAT ».
- Saisir les valeurs de x dans *List1* et les valeurs de y dans *List2*.
- Sélectionner « CALC » puis « SET ».
- Choisir *List1* pour *2Var XList* et *List2* pour *2Var YList* puis « EXE ».
- Sélectionner « REG » puis « X » et « aX+b ».

La calculatrice nous renvoie : $a = 2{,}138095238$ et $b = 1{,}142857143$.

Une équation de la droite d'ajustement est :

$$y = 2{,}1x + 1{,}1.$$

Pour tracer la droite, il suffit de calculer les coordonnées de deux points de la droite d'ajustement :

- si $x = 0$, alors $y = 2{,}1 \times 0 + 1{,}1 = 1{,}1$: le point de coordonnées $(0\,;1{,}1)$ appartient à la droite d'ajustement ;
- si $x = 10$, alors $y = 2{,}1 \times 10 + 1{,}1 = 22{,}1$: le point de coordonnées $(10\,;22{,}1)$ appartient à la droite d'ajustement.

3) Pour $y = 70$, on lit graphiquement $x \approx 33$.

Par le calcul, si $y = 70$, alors $70 = 2{,}1x + 1{,}1$, soit $2{,}1x = 70 - 1{,}1$, c'est-à-dire $2{,}1x = 68{,}9$, donc

$$x = \frac{68{,}9}{2{,}1} \approx 32{,}8.$$

Les calculs sont réalisés dans le domaine d'étude : on parle donc d'**interpolation**.

III Ajustement par changement de variable

Lorsque le nuage de points n'est à priori pas modélisable par une droite, on peut réaliser un ajustement linéaire en effectuant un changement de variable.

Exercice

Effectuer un ajustement se ramenant par changement de variable à un ajustement affine.
On a relevé la population d'une grande métropole sur 50 ans tous les 5 ans. Les résultats sont présentés dans le tableau suivant :

Année x_i	0	5	10	15	20	25	30	35	40	45	50
Population en milliers y_i	19,4	19,4	27,6	40,3	50	59	69	87	132	166	216

1) Représenter le nuage de points dans un repère.

2) a) On effectue le changement de variable $z = \log y$. Réaliser un nouveau tableau présentant les valeurs prises par les variables x et z.

b) Représenter un nouveau nuage de points à partir des données des variables x et z.

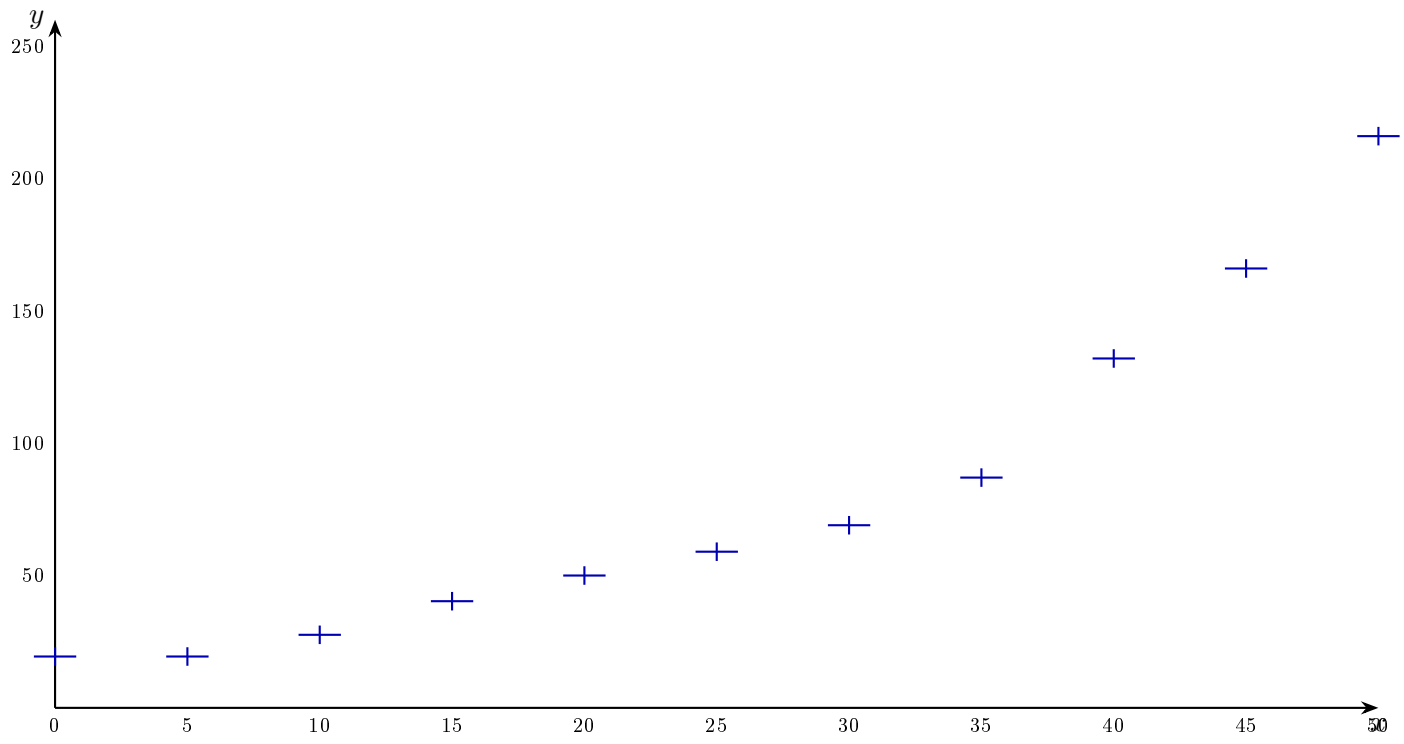
c) À l'aide de la calculatrice, déterminer une équation de la droite d'ajustement de z en x par la méthode des moindres carrés. Représenter la droite d'ajustement.

3) a) En déduire la relation qui lie y et x, puis tracer la courbe représentative de la fonction f définie par $y = f(x)$ dans le repère contenant le premier nuage de points.

b) En admettant que le modèle mathématique reste valable en dehors du domaine d'étude, extrapoler le nombre d'habitants 5 ans après l'étude.

Correction.

1)

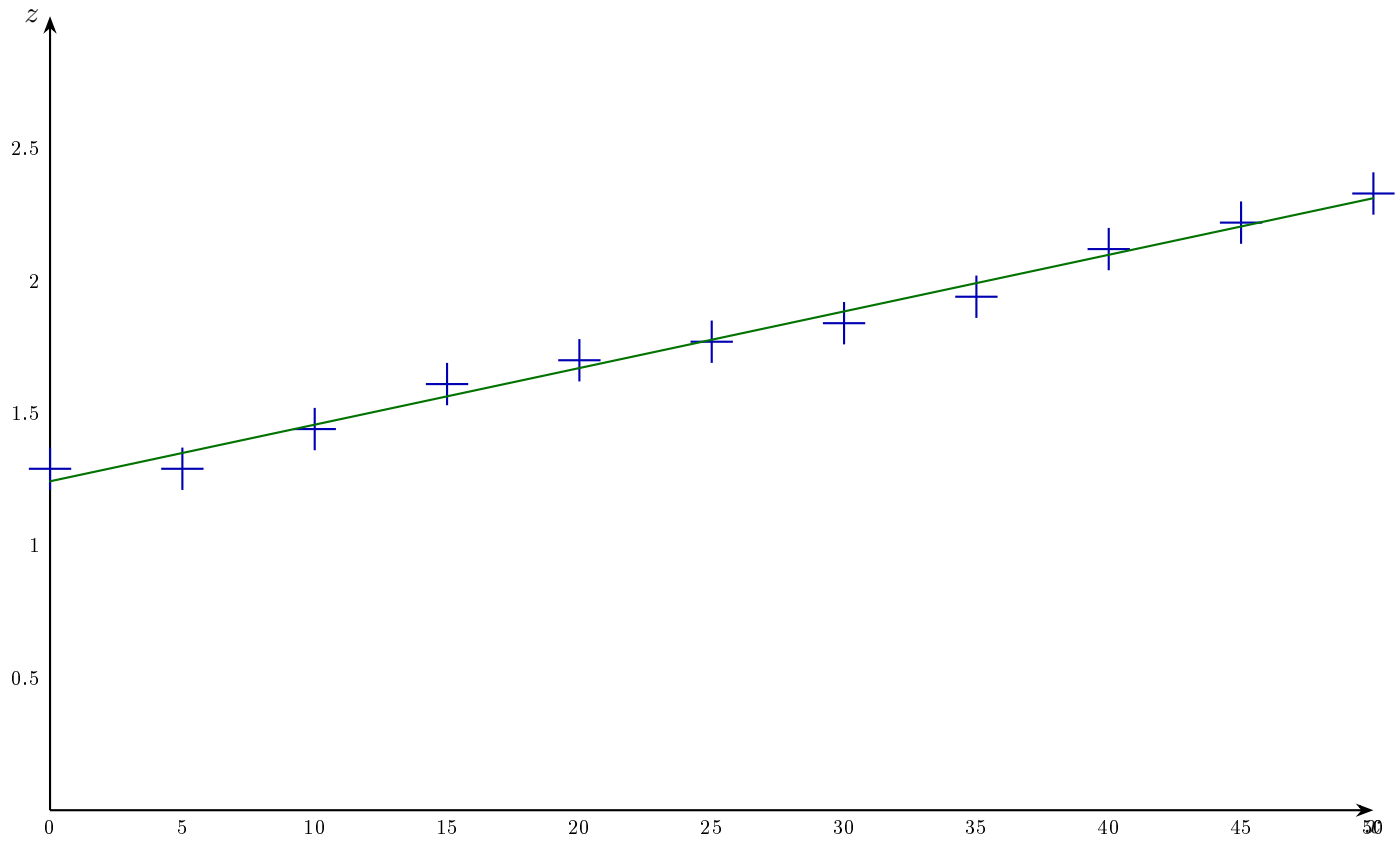


2) a)

x_i	0	5	10	15	20	25	30	35	40	45	50
$z_i = \log y_i$	1,29	1,29	1,44	1,61	1,7	1,77	1,84	1,94	2,12	2,22	2,33

b) et **c)** Une équation de la droite d'ajustement est :

$$z = 0{,}0214x + 1{,}2427.$$



RegLin
$y = ax + b$
$a = 0.0213818182$
$b = 1.242727273$
$r^2 = 0.9883906748$
$r = 0.9941783918$

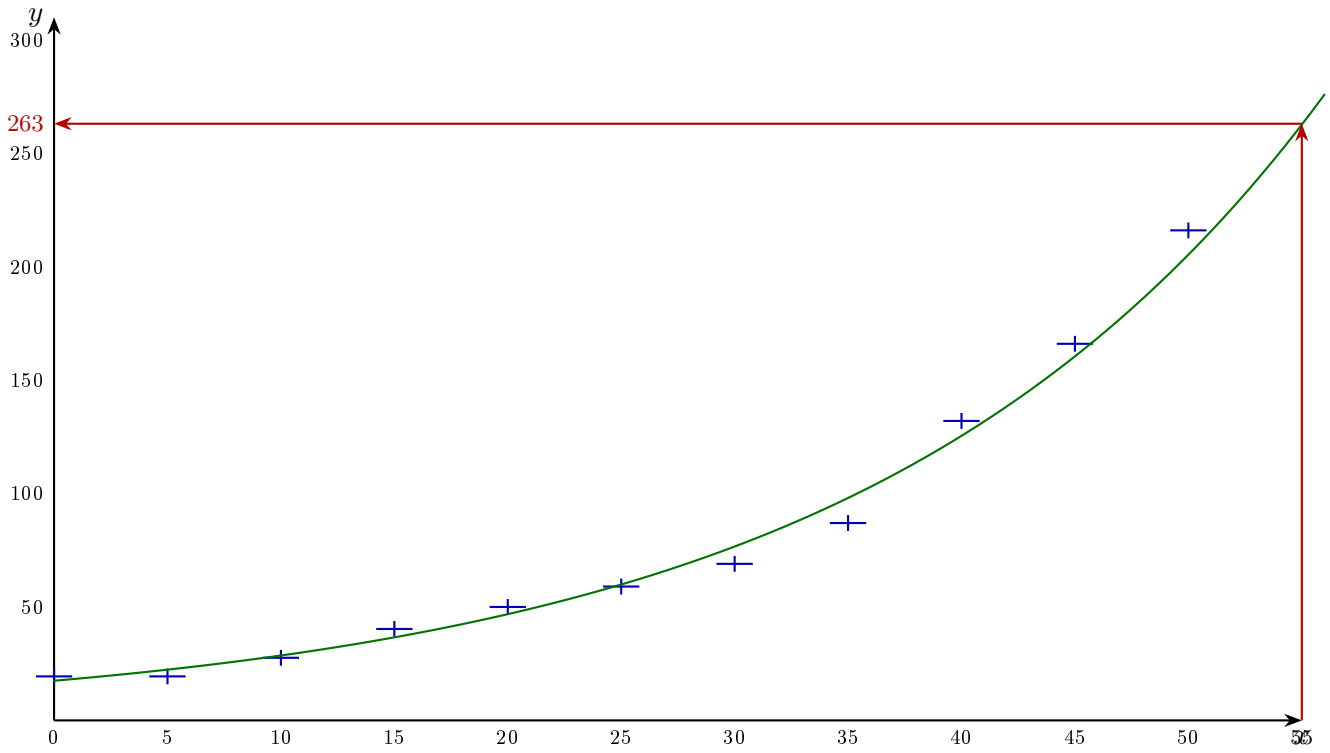
3) a) On a : $z = 0{,}0214x + 1{,}2427$ et $z = \log y$, soit :

$$\begin{aligned} \log y &= 0{,}0214x + 1{,}2427 \\ y &= 10^{\log y} = 10^{0{,}0214x+1{,}2427} \\ y &= 10^{0{,}0214x} \times 10^{1{,}2427} \\ y &= 17{,}4864 \times 10^{0{,}0214x}. \end{aligned}$$

Donc

$$f(x) = 17{,}4864 \times 10^{0{,}0214x}$$

est l'expression de la fonction permettant d'ajuster le nuage de points $(x_i\,;y_i)$. On trace la courbe de f ci-dessous.



b)

$$y = 17{,}4864 \times 10^{0{,}0214 \times 55} \approx 263.$$

On peut supposer que 5 années après la fin de l'étude, la population de la ville sera proche de 263 000 habitants.